DIFFUSION MODELS

SENAI CIMATEC

Bianca Andrade
Rafael Athaliba
Pedro Lima



SUMÁRIO

- Fundamentação
- Arquitetura
- Implementação
- Avaliação experimental
- Demonstração
- Conclusão

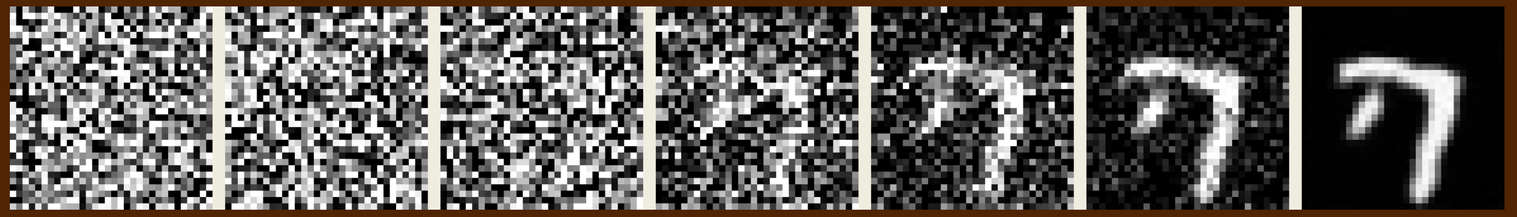
01

FUNDAMENTAÇÃO

Como a técnica funciona

O QUE SÃO DIFFUSION MODELS?

Modelos generativos que criam imagens novas removendo gradualmente o ruído de uma imagem aleatória.



ruído → imagem gerada

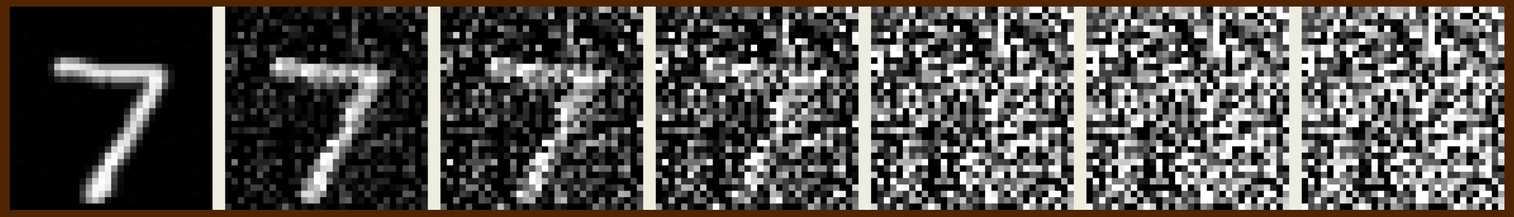
Aplicações: **Stable Diffusion** · **DALL·E 2** · **Sora**

LINHA DO TEMPO

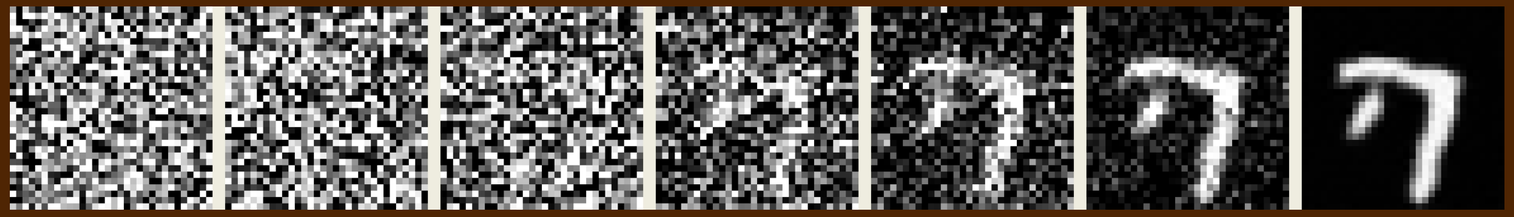
2015	2020	2022	2024	2025	2026
Primeira formulação inspirada na termodinâmica	**DDPM** imagens de alta qualidade	**Stable Diffusion** código aberto	**Sora** geração de vídeo (OpenAI)	**Veo 3 · Gemini Diffusion** vídeo com áudio · texto	**Mercury 2** modelo de linguagem por difusão

PROCESSO DIRETO E REVERSO

1 Processo direto — adição de ruído (cálculo fixo)



2 Processo reverso — remoção de ruído (aprendida pela rede)



Geração: aplica-se o processo reverso a partir de ruído puro.

TREINAMENTO DA REDE

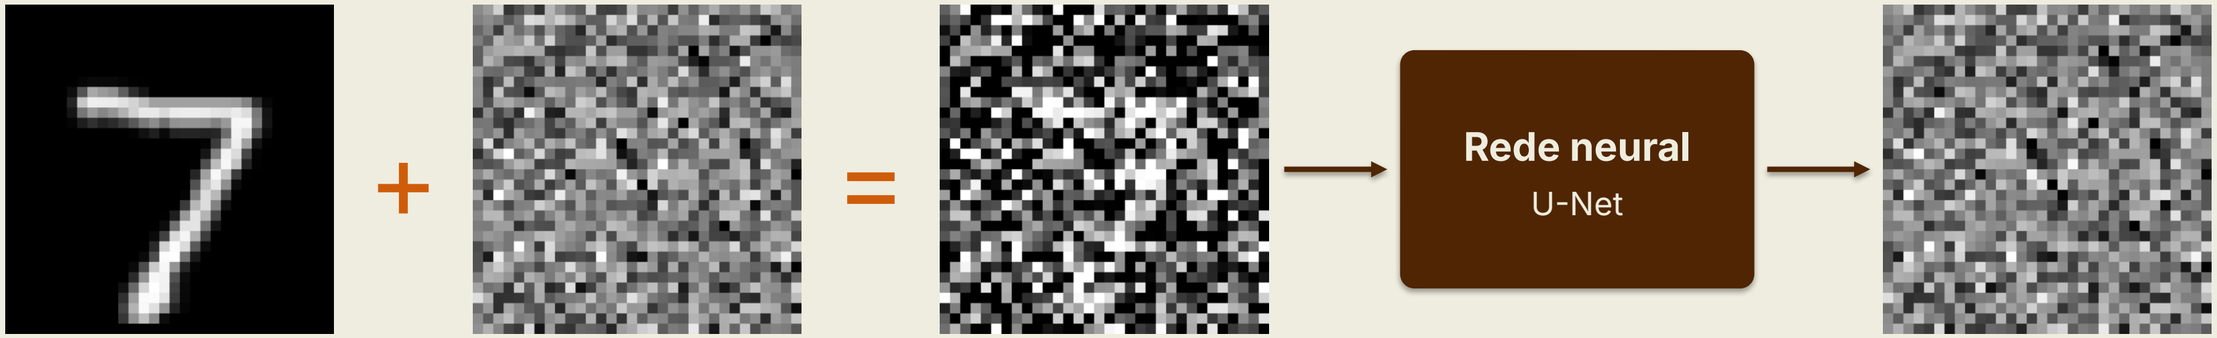
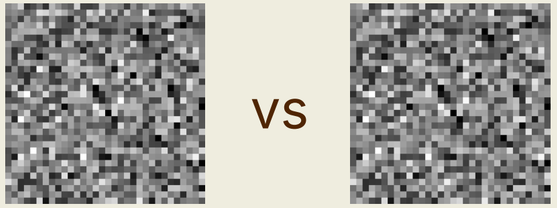


imagem real | ruído aleatório | imagem com ruído | ruído previsto



Erro (MSE) = 0,0075 → atualização dos pesos da rede

Aprendizado supervisionado: o alvo é o ruído adicionado, conhecido de antemão.

CARACTERÍSTICAS

1

Treinamento estável

uma única rede e uma função de erro simples (MSE)

2

Alta diversidade

cada ruído inicial gera uma imagem diferente

3

Geração condicionada

por texto, classe ou esboço

4

Qualidade × velocidade

mais passos aumentam a qualidade e o tempo

COMPARAÇÃO COM OUTROS MODELOS

	GAN	VAE	Difusão
Qualidade das imagens	Alta	Média (borradas)	Muito alta
Diversidade	Baixa	Alta	Alta
Estabilidade do treino	Instável	Estável	Estável
Velocidade de geração	Alta	Alta	Baixa (vários passos)

GAN: técnica apresentada em aula (site Which Face Is Real).

LIMITAÇÕES

- **Geração lenta:** exige muitos passos
- **Alto custo** de treinamento
- **Dificuldade** com texto legível, rostos e composição*
- **Pode reproduzir** imagens do treinamento**
- **Risco de uso indevido** (deepfakes)

* cartão oficial do Stable Diffusion · ** Carlini et al., 2023

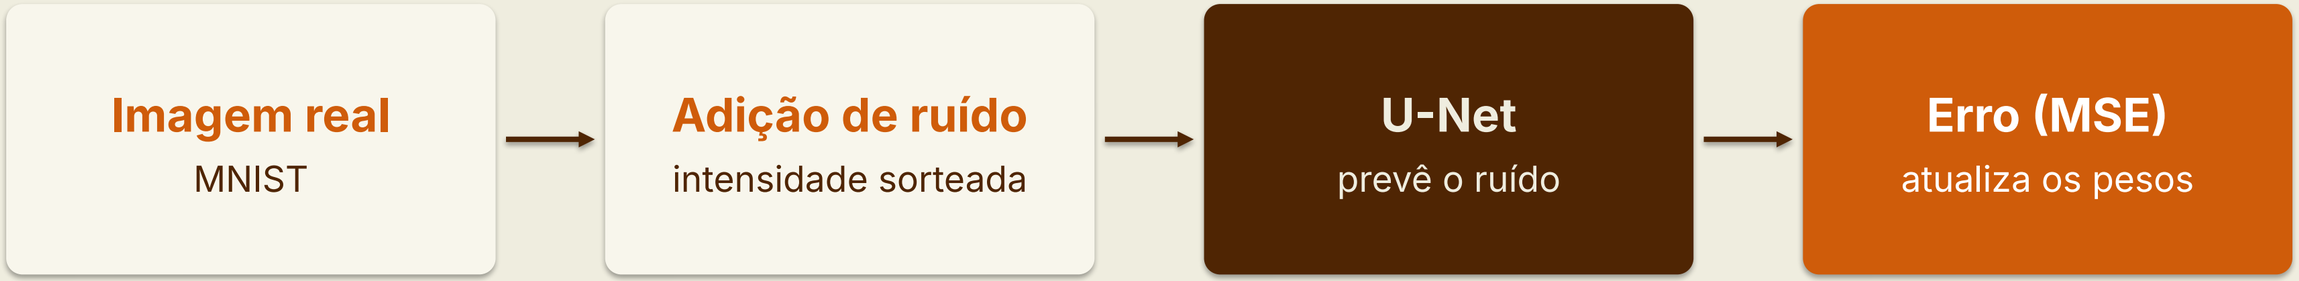
02

ARQUITETURA

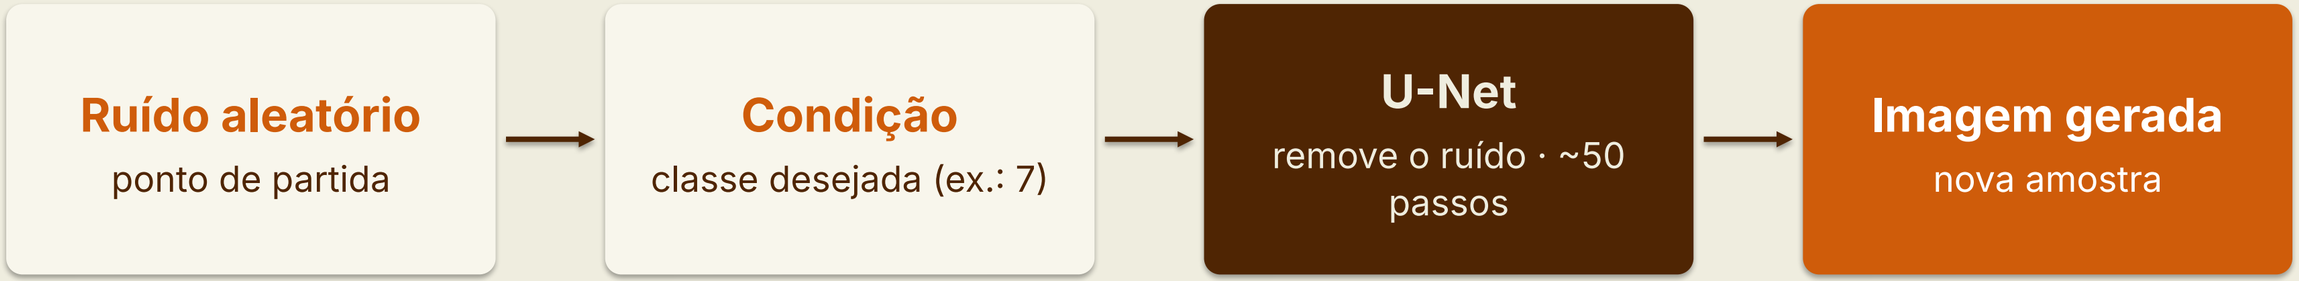
Fluxo de dados e componentes

FLUXO DE DADOS

TREINAMENTO

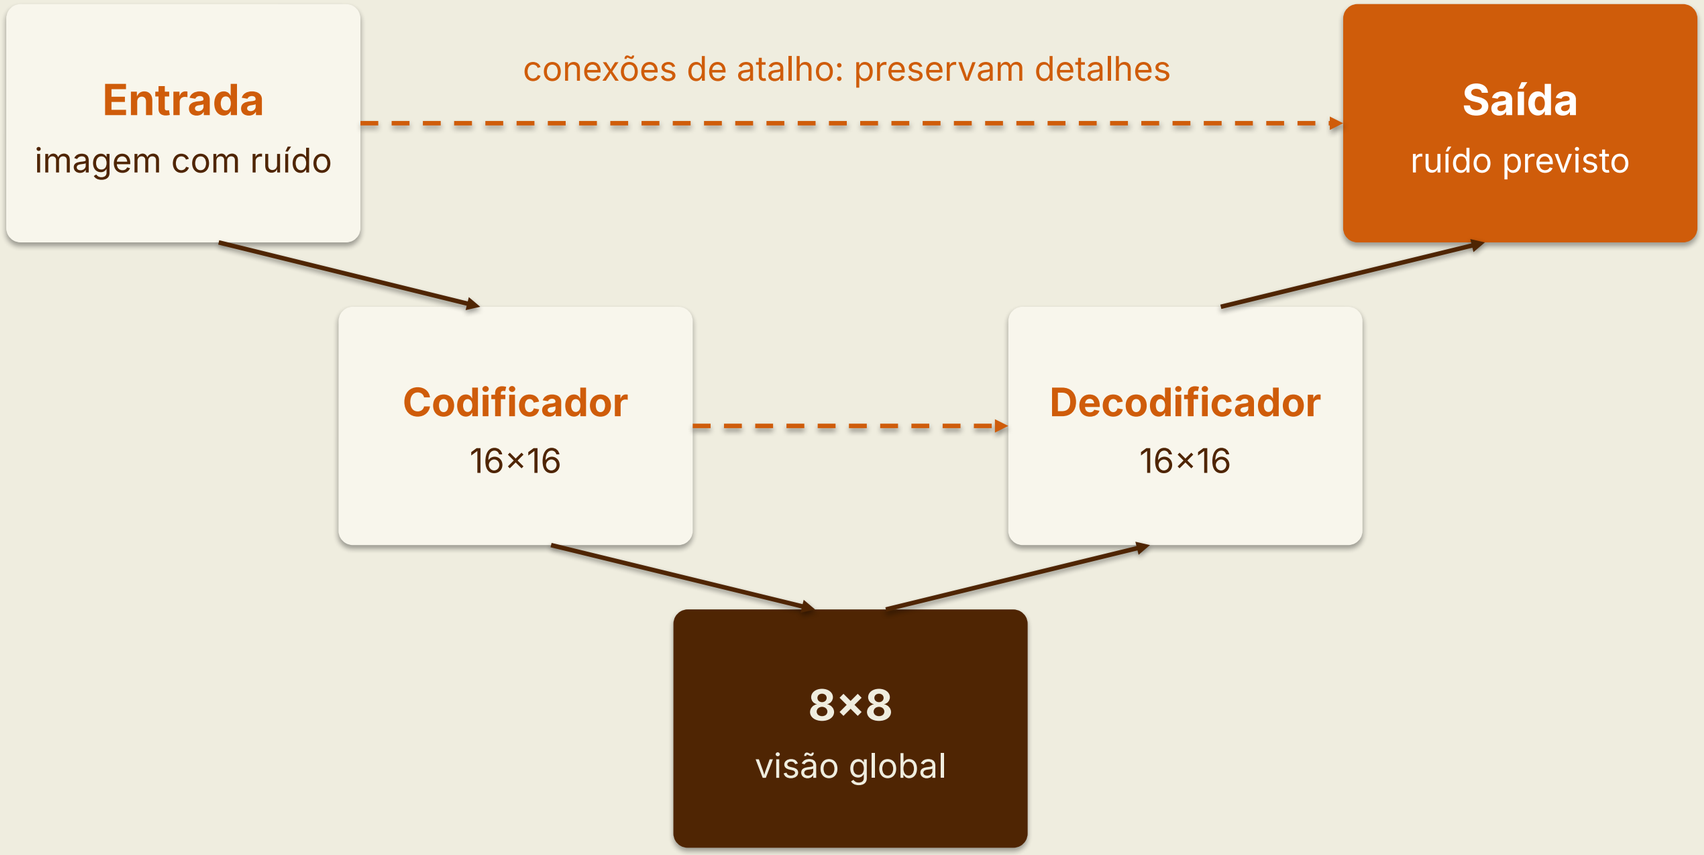


GERAÇÃO



Em 10% do treinamento a classe é omitida, o que permite controlar a intensidade do condicionamento (guidance).

ARQUITETURA DA REDE: U-NET



Entradas adicionais:

Passo t
nível de ruído atual

Classe
dígito desejado (0–9)

~750 mil
parâmetros

STABLE DIFFUSION



~1 bi
parâmetros (U-Net + codificador de texto)

48× menor
espaço latente (64×64×4)

5 bi
pares imagem-texto (LAION-5B)

Mesmo princípio do nosso modelo, aplicado em larga escala.

03

IMPLEMENTAÇÃO

Treinamento do zero no Google Colab

O EXPERIMENTO

60 mil
imagens de dígitos manuscritos (MNIST)

~750 mil
parâmetros da U-Net

10 épocas
~95 min de treinamento (CPU)

1000
passos de difusão

LOOP DE TREINAMENTO

```
t     = sortear_passo()
ruido = gerar_ruido()
x_t   = adicionar_ruido(x0, t, ruido)
prev  = unet(x_t, t, classe)
erro  = mse(prev, ruido)
atualizar_pesos(erro)
```

Linhas 1–3
entrada com ruído

Linhas 4
previsão da rede

Linhas 5–6
erro e atualização

Pseudocódigo · implementação completa no notebook

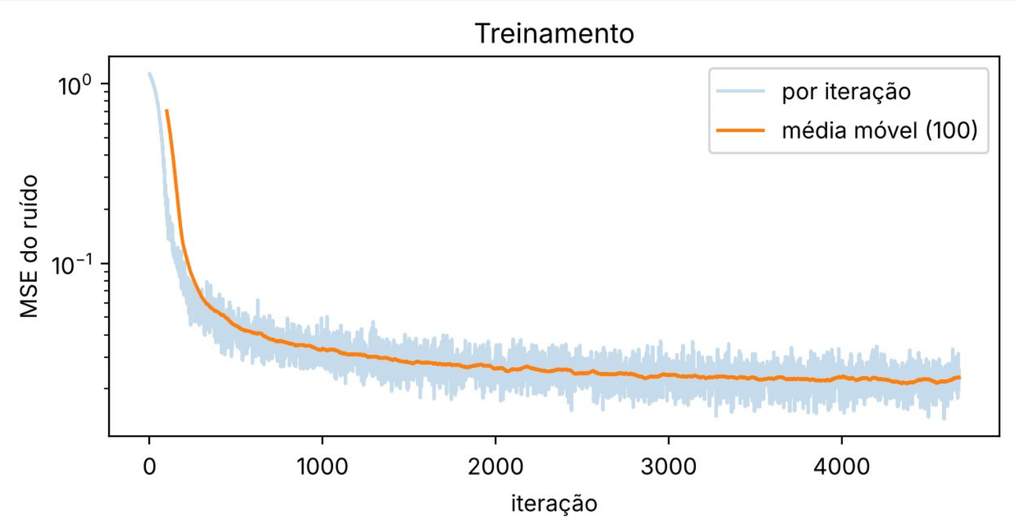
04

AVALIAÇÃO

Resultados, métricas e erros

TREINAMENTO E AMOSTRAS

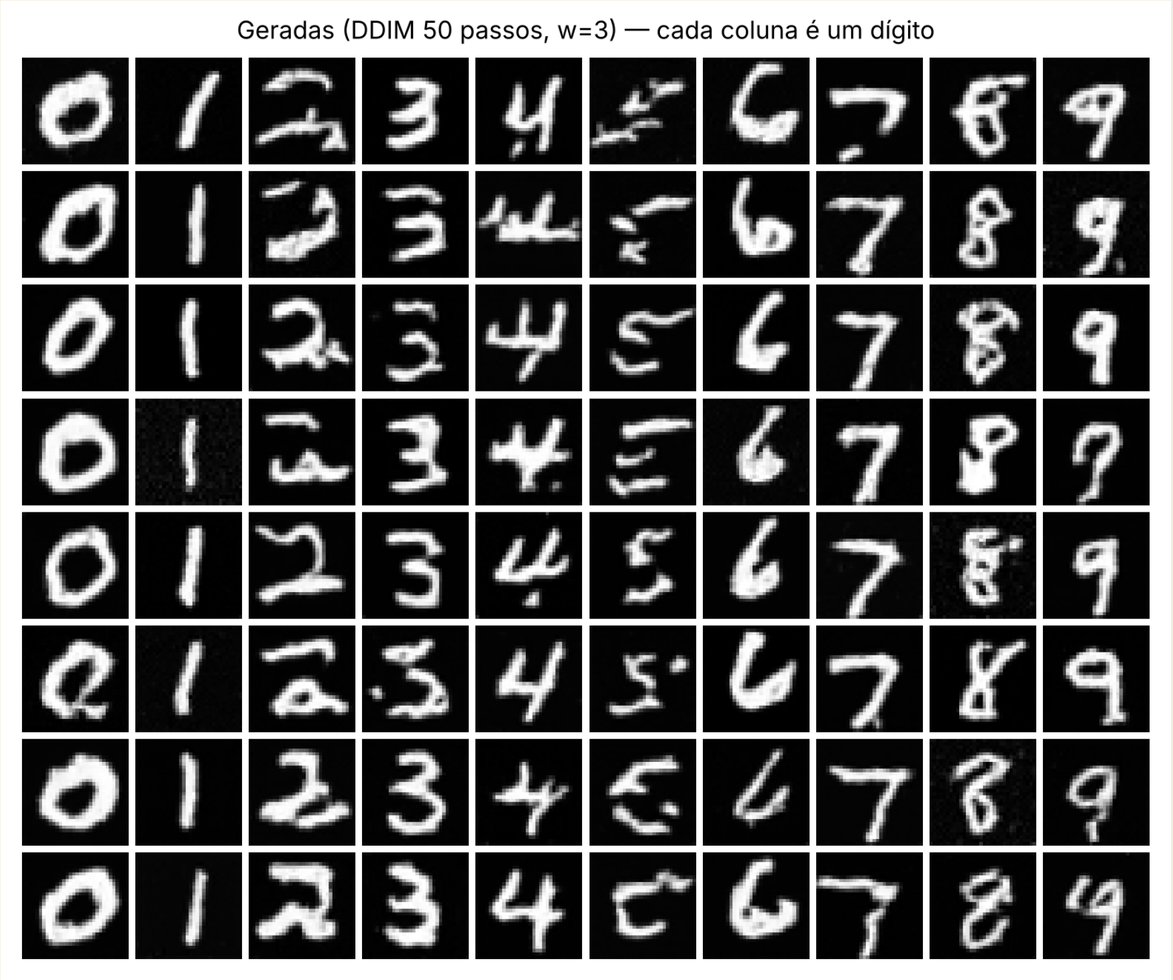
Curva de erro (loss)



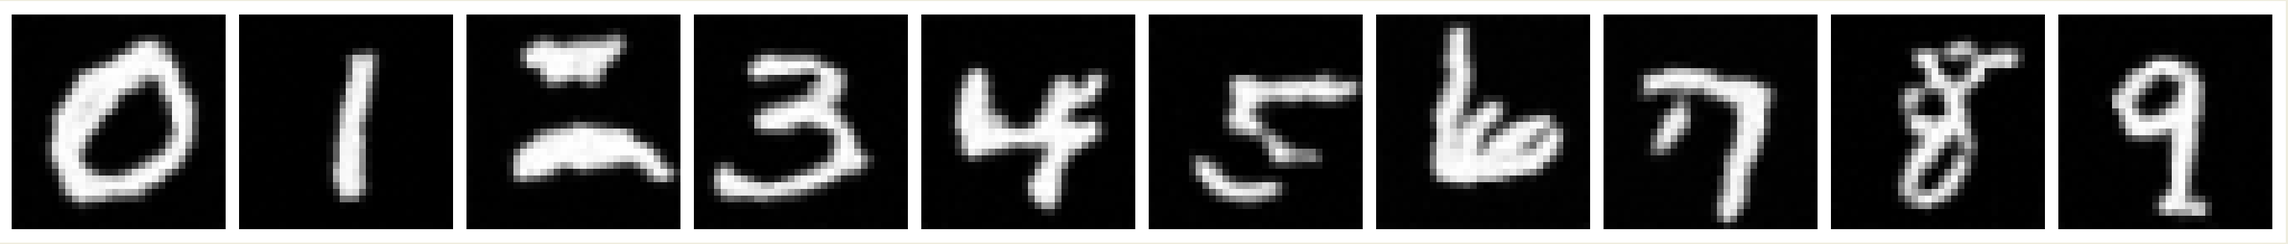
~1 → 0,022

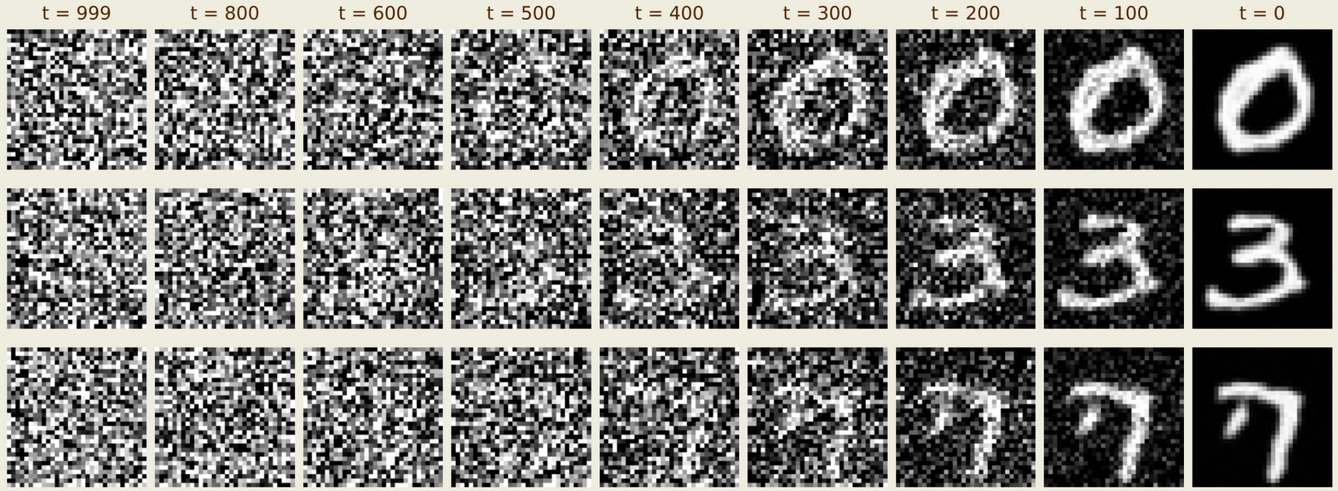
erro médio ao longo de 10 épocas

Amostras geradas (coluna = classe)



PROCESSO REVERSO E DIVERSIDADE





16 amostras da classe 4



cada amostra é diferente

PRINCIPAIS RESULTADOS

97%

das amostras reconhecidas como a classe solicitada

19×

mais rápido com 50 passos (DDIM) do que com 1000 (DDPM)

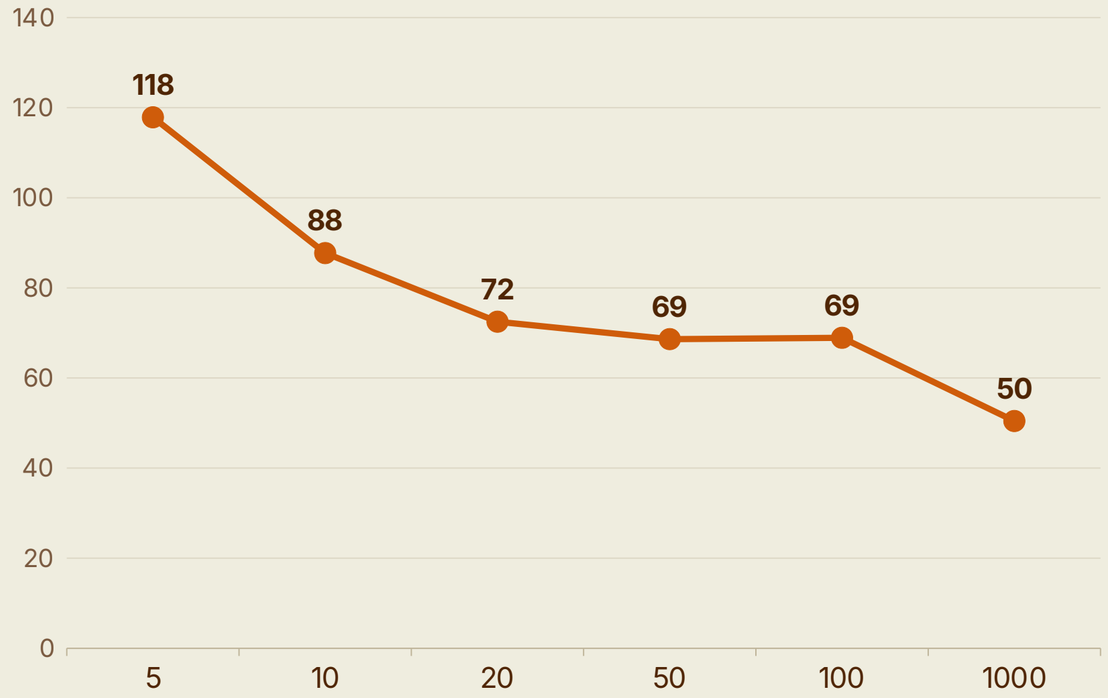
2,8%

classificadas como outro dígito (14 de 500)

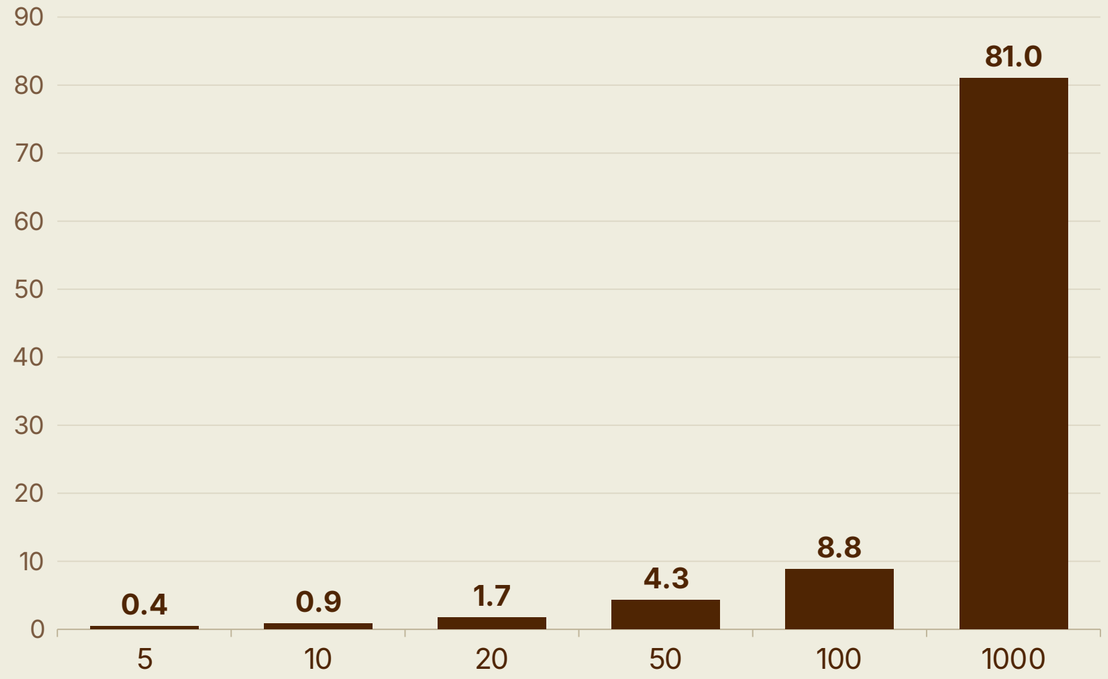
500 amostras por configuração · acurácia medida por um classificador CNN treinado no MNIST

QUALIDADE × NÚMERO DE PASSOS

FID (quanto menor, melhor)



Tempo de geração (min, CPU)

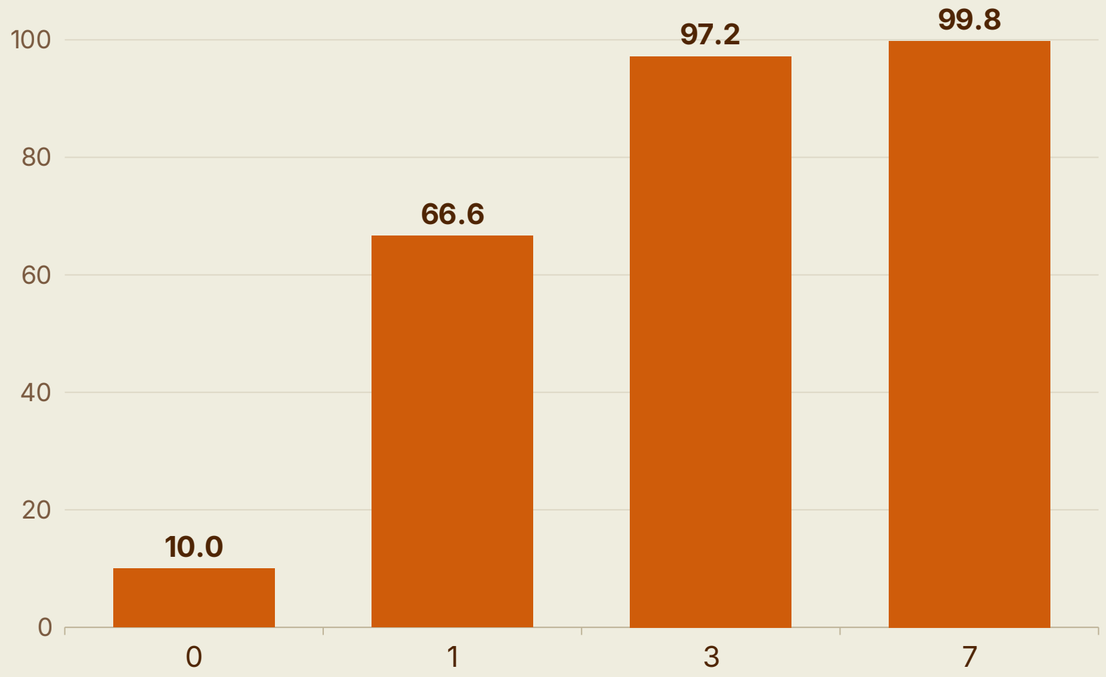


número de passos →

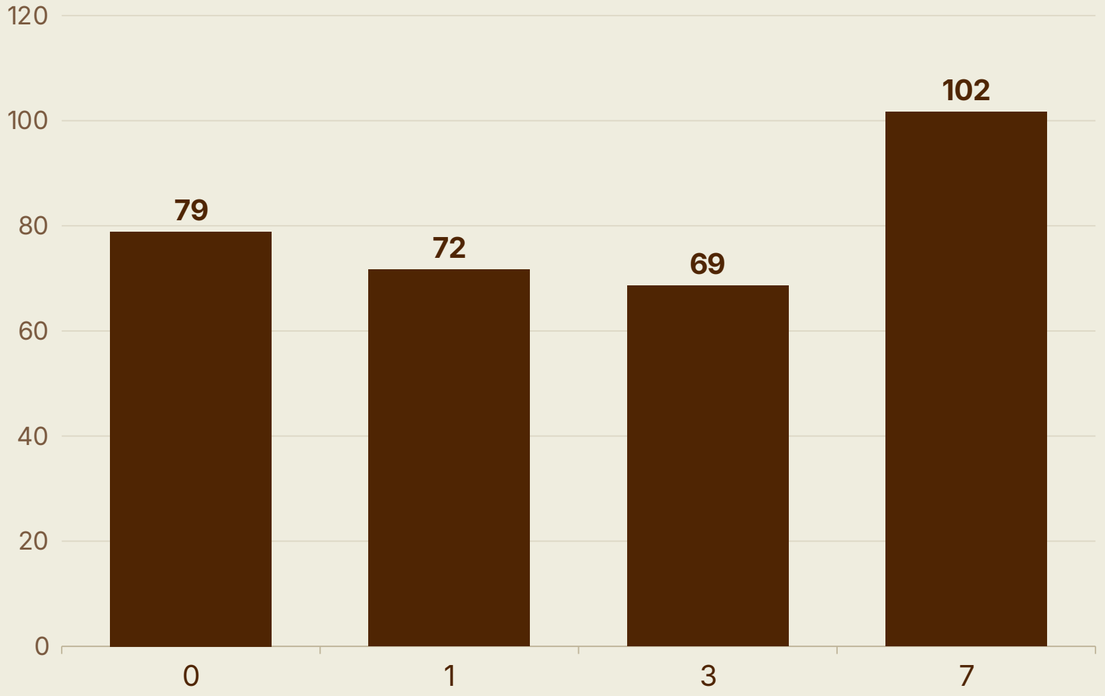
50 passos: qualidade próxima e geração cerca de 19× mais rápida

EFEITO DO GUIDANCE

Acurácia condicional (%)



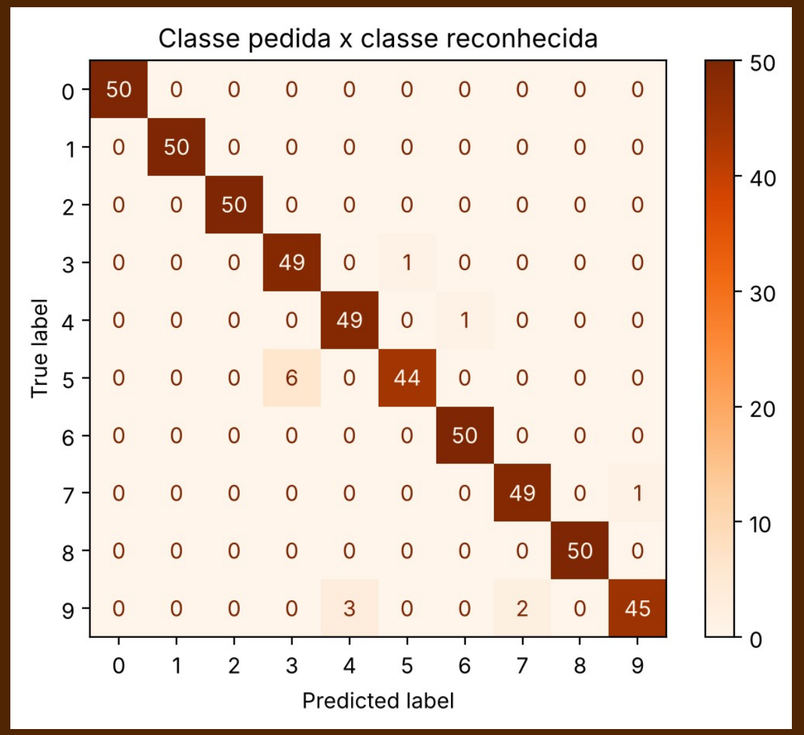
FID (quanto menor, melhor)

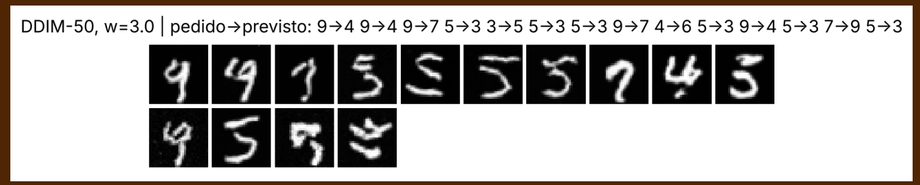


intensidade do guidance (w) →

w = 3: melhor equilíbrio · w = 0 ignora a classe · w = 7 reduz a qualidade

ERROS OBSERVADOS





Classe 5 gerada como 3

6 casos

Classe 9 gerada como 4 ou 7

5 casos

Dígitos de formas semelhantes

LIMITAÇÕES DO EXPERIMENTO

- **MNIST:** imagens simples, em tons de cinza
- **Modelo pequeno,** apenas 10 épocas
- **Classificador avaliador:** 95,6% de acurácia
- **Stable Diffusion** utilizado pré-treinado

05

DEMONSTRAÇÃO

Execução no Google Colab

DEMONSTRAÇÃO

1 · MODELO TREINADO (MNIST)

1. Geração da classe 7
2. 5 × 50 passos
3. Guidance: w = 0 × w = 8
4. Variação da semente

2 · STABLE DIFFUSION

1. Geração a partir de texto
2. Imagem em 1 passo (SD-Turbo)
3. Mesmo princípio, em larga escala

Plano de contingência: vídeo gravado da demonstração

CONCLUSÃO

- **Aprendem a remover ruído;** a geração parte de ruído puro
- **Treinamento supervisionado** com erro quadrático médio (MSE)
- **Nosso modelo:** 97% das amostras na classe solicitada

Um modelo que aprende a remover ruído é capaz de gerar dados novos.

REFERÊNCIAS

SOHL-DICKSTEIN, J. et al. Deep Unsupervised Learning using Nonequilibrium Thermodynamics. ICML, 2015.

HO, J.; JAIN, A.; ABBEEL, P. Denoising Diffusion Probabilistic Models. NeurIPS, 2020.

SONG, J.; MENG, C.; ERMON, S. Denoising Diffusion Implicit Models. ICLR, 2021.

HO, J.; SALIMANS, T. Classifier-Free Diffusion Guidance. 2022.

ROMBACH, R. et al. High-Resolution Image Synthesis with Latent Diffusion Models. CVPR, 2022.

CARLINI, N. et al. Extracting Training Data from Diffusion Models. USENIX Security, 2023.

OPENAI. Video generation models as world simulators (Sora). 15 fev. 2024.

GOOGLE DEEPMIND. Gemini Diffusion. 20 maio 2025.

THE DECODER. Inception launches Mercury 2. 24 fev. 2026.

STABILITY AI / COMPVIS. Model cards: stable-diffusion-v1-4 e sd-turbo (Hugging Face).

CARDIA, L. Introdução à IA Generativa (Aula 20). SENAI CIMATEC.

OBRIGADO

Perguntas?

Bianca Andrade · Rafael Athaliba · Pedro Lima